Tecnológico Nacional de México

Campus Querétaro

Presenta:

Nombre	Número de Control
Diego Hernandez Hernandez	**22140273**

Estudiantes de la carrera:

Ingeniería industrial

Inscrito en:

Materia	Grupo
Ingenieria de Datos	**EC1**

Docente:

Sandra Lucia de la Fuente Bermudez

Resumen

Fecha de entrega: 17/03/2026

Introducción

La guía explica cómo aplicar Machine Learning para resolver un problema de clasificación binaria utilizando herramientas como Python, scikit-learn, XGBoost y LightGBM.

El ejercicio se basa en la competencia *March Machine Learning Mania 2026* de Kaggle, donde el objetivo es predecir el ganador de partidos de basquetbol universitario usando datos históricos.

Además, se muestra cómo evaluar modelos de clasificación y cómo construir un pipeline completo de Machine Learning.

Fundamentos de Clasificación Binaria

La clasificación binaria consiste en predecir una de dos posibles clases, por ejemplo: ganar/perder, sí/no o 1/0.

Para evaluar el modelo se utiliza la matriz de confusión, la cual incluye:

- True Positive (TP)
- False Positive (FP)
- False Negative (FN)
- True Negative (TN)

Métricas de Evaluación

Las métricas principales son:

- Accuracy: porcentaje de predicciones correctas.
- Precision: qué tan correctas son las predicciones positivas.
- Recall: qué porcentaje de los positivos reales detecta el modelo.
- F1 Score: equilibrio entre precision y recall.

Curva ROC y AUC

La curva ROC muestra el rendimiento del modelo comparando el True Positive Rate con el False Positive Rate.

El AUC (Área Bajo la Curva) mide la capacidad del modelo para distinguir entre clases.
Un valor cercano a 1 indica un modelo excelente.

Competencia March Machine Learning Mania

El objetivo es predecir la probabilidad de que un equipo gane un partido del torneo NCAA.

El modelo debe generar probabilidades, no solo clasificaciones.

La métrica utilizada para evaluar el desempeño es Log Loss.

Pipeline de Machine Learning

El proceso incluye las siguientes etapas:

1. Carga de datos
2. Limpieza de datos
3. Feature engineering
4. Entrenamiento del modelo
5. Evaluación del modelo

Sistema Elo

El sistema Elo asigna una puntuación a cada equipo según su desempeño.

Después de cada partido, el rating se actualiza. La diferencia de Elo entre equipos se vuelve una variable importante para predecir el ganador.

Modelos de Machine Learning

La guía menciona varios modelos utilizados:

- Logistic Regression
- Random Forest
- XGBoost
- LightGBM

Estos modelos permiten identificar patrones en los datos y mejorar las predicciones

Conclusión

Un buen modelo depende principalmente de un buen *feature engineering*, del uso de métricas adecuadas y de una validación correcta.

Modelos como XGBoost y LightGBM suelen ofrecer muy buenos resultados en competencias de Machine Learning.

Además, muchas veces la calidad de las variables utilizadas puede ser más importante que el modelo en sí.