Resumen de la guía, clasificación Binaria y March Machine Learning Mania 2026

10/03/2026 Fecha

—

Nombre: Ximena Guadalupe Ibarra Santiago
TecNM Campus Querétaro

Nombre de la Unidad:

Nombre de la materia: Ingeniería de datos

- **Introducción**

La guía explica cómo aplicar Machine Learning para resolver un problema de clasificación binaria utilizando herramientas como Python, scikit-learn, XGBoost y LightGBM.
El ejercicio se basa en la competencia March Machine Learning Mania 2026 de Kaggle, donde el objetivo es predecir el ganador de partidos de basquetbol universitario usando datos históricos.
También se muestra cómo evaluar modelos de clasificación y construir un pipeline completo de Machine Learning.

- **Fundamentos de Clasificación Binaria**

La clasificación binaria consiste en predecir una de dos posibles clases, por ejemplo ganar/perder, sí/no o 1/0.
Para evaluar el modelo se utiliza la matriz de confusión, que incluye: True Positive (TP), False Positive (FP), False Negative (FN) y True Negative (TN).

- **Métricas de Evaluación**

Las métricas principales incluyen:
- Accuracy: porcentaje de predicciones correctas.
- Precision: qué tan correctas son las predicciones positivas.
- Recall: qué porcentaje de los positivos reales detecta el modelo.
- F1 Score: equilibrio entre precision y recall.

- **Curva ROC y AUC**

La curva ROC muestra el rendimiento del modelo comparando el True Positive Rate con el False Positive Rate.
El AUC (Área Bajo la Curva) mide la capacidad del modelo para distinguir entre clases.
Un valor cercano a 1 indica un modelo excelente.

- **Competencia March Machine Learning Mania**

El objetivo es predecir la probabilidad de que un equipo gane un partido del torneo NCAA.
El modelo debe generar probabilidades y no solo clasificaciones.
La métrica utilizada para evaluar el desempeño es Log Loss.

Pipeline de Machine Learning

El proceso incluye:
1. Carga de datos

2. Limpieza de datos
3. Feature engineering
4. Entrenamiento del modelo
5. Evaluación del modelo

- **Sistema Elo**

El sistema Elo asigna una puntuación a cada equipo según su desempeño. Después de cada partido el rating se actualiza. La diferencia de Elo entre equipos es una variable importante para predecir el ganador.

- **Modelos de Machine Learning**

La guía menciona varios modelos utilizados:
- Logistic Regression
- Random Forest
- XGBoost
- LightGBM

Estos modelos permiten identificar patrones en los datos para mejorar las predicciones.

Conclusión

Un buen modelo depende principalmente de un buen feature engineering, el uso de métricas adecuadas y una validación correcta. Modelos como XGBoost y LightGBM suelen ofrecer buenos resultados en competencias de Machine Learning. Además, la calidad de las variables utilizadas puede ser más importante que el modelo en sí.